실전 AI 개발

Day3

프로젝트 시작 · 데이터 이해

- 개인 프로젝트 안내
  - Day3: 데이터 이해 · EDA
  - Day4: 데이터 전처리 · Baseline 모델링
  - Day5: 성능 개선 실험
  - Day6: 최적 모델 선택 및 성능 측정 · 결과 해석 · 결과발표

프로젝트 시작 · 데이터 이해

- 데이터 소개
  - Online Shoppers Purchasing Intention
    - 온라인 쇼핑 세션 데이터 분석
    - 목표: 고객의 구매 여부(Revenue) 예측
    - 문제 유형: Classification
    - UCI Machine Learning Repository 공개 데이터
    - 12,330개 온라인 쇼핑 세션
    - 각 행(row)은 한 번의 웹사이트 방문 세션
    - 입력 Feature 17개 + Target Revenue
    - 결측치 없음
    - 약 1년간의 데이터를 사용하며, 특정 사용자의 반복 방문 효과를 줄이도록 각 세션이 서로 다른 사용자에 해당하도록 구성됨

프로젝트 시작 · 데이터 이해

Administrative	계정 관리, 주문 관리 등 관리 목적 페이지를 방문한 횟수
Administrative_Duration	관리 목적 페이지에 머문 총 시간
Informational	사이트나 상품 관련 정보 제공 페이지를 방문한 횟수
Informational_Duration	정보 제공 페이지에 머문 총 시간
ProductRelated	상품 관련 페이지를 방문한 횟수
ProductRelated_Duration	상품 관련 페이지에 머문 총 시간
BounceRates	방문 후 추가 행동 없이 사이트를 이탈하는 정도를 나타내는 지표
ExitRates	해당 페이지가 세션의 마지막 페이지가 되는 정도를 나타내는 지표
PageValues	구매로 이어지는 과정에서 방문 페이지가 갖는 가치를 나타내는 지표
SpecialDay	방문일이 밸런타인데이, 어머니날 등 특정 기념일과 얼마나 가까운지를 나타내는 값
Month	방문이 발생한 월
OperatingSystems	사용자의 운영체제 종류를 나타내는 코드
Browser	사용한 브라우저 종류를 나타내는 코드
Region	사용자가 속한 지역을 나타내는 코드
TrafficType	사용자가 사이트에 유입된 경로 유형을 나타내는 코드
VisitorType	방문자 유형 (Returning_Visitor, New_Visitor 등)
Weekend	방문일이 주말인지 여부
Revenue	해당 세션에서 실제 구매가 발생했는지 여부

프로젝트 시작 · 데이터 이해

- 오늘의 목표
  - 데이터 구조 파악
    - Target 확인
    - 데이터 품질 확인
    - 주요 Feature와 Target 관계 분석
    - Class Imbalance 확인
    - 이후 모델링 방향 설정

프로젝트 시작 · 데이터 이해

- 데이터 기초 확인 질문
  - 결측치가 있는가?
  - 한 행은 무엇을 의미하는가?
  - Target은 무엇인가?
  - Target 비율은 균형적인가?
  - Numerical / Categorical Feature는 무엇인가?
  - 비슷한 의미의 변수가 있는가?
  - 구매 여부와 관련 있을 것 같은 변수는 있는가?
  - Encoding, Scaling 이 필요해 보이는 변수가 있는가?
  - 이상하거나 해석하기 어려운 값은 없는가?

프로젝트 시작 · 데이터 이해

- 탐색적 데이터 분석
  - 그래프, 통계 분석을 많이 하는 것이 목적이 아님
  - 구매한 세션과 구매하지 않은 세션은 무엇이 다른가?
  - 이 차이를 모델이 사용할 수 있도록 어떻게 표현할 수 있을까?
  - 주요 확인 질문
    - 상품 페이지를 많이 보면 실제 구매율이 높아지는가?
    - 상품 페이지 체류시간이 길수록 구매할까?
    - PageValues가 높은 세션에서 구매가 많이 발생하는가?
    - 신규 방문자와 재방문자의 구매율은 다른가?
    - 주말과 평일은 차이가 있는가?
    - 특정 월에 구매가 집중되는가?
    - Bounce / Exit Rate가 높으면 구매율이 낮은가?

프로젝트 시작 · 데이터 이해

- DAY 3 달성 기준
  - 데이터 구조 및 컬럼 의미 파악
  - Target(Revenue) 및 클래스 분포 확인
  - 주요 Feature 분포 확인
  - 주요 Feature와 Target 관계 분석
  - 이상치·특이값 확인
  - 전처리가 필요한 변수 정리
  - Feature Engineering 아이디어 정리
  - DAY 4 모델링 방향 정리

프로젝트 시작 · 데이터 이해

- Day3 고찰 (텍스트 셀 추가하여 해당 내용 작성)
  - 구매 여부와 관련 있어 보였던 Feature는 무엇인가?
  - 예상과 다른 패턴을 보인 Feature는 무엇인가?
  - 전처리가 필요하다고 판단한 변수와 그 이유는?
  - 추가로 만들어보고 싶은 Feature는 무엇인가?
  - DAY 4에서 가장 먼저 확인하고 싶은 모델링 결과는 무엇인가?